

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
федеральное государственное бюджетное образовательное
учреждение высшего образования
«УЛЬЯНОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ
УНИВЕРСИТЕТ»

Факультет информационных систем и технологий
Кафедра «Измерительно-вычислительные комплексы»

«Системы искусственного интеллекта»

Отчет по лабораторной работе №5

Выполнила:
студентка
гр. ИСТбд-31
Феофанова П.А.

Проверил:
Шишкин В.В.

Ульяновск, 2026 г.

Введение

Регрессия — раздел машинного обучения, в котором по набору признаков предсказывается числовое значение целевой переменной. В отличие от классификации, где цель дискретна (классы), в регрессии ответ непрерывен (например, цена, температура, доход).

Библиотека Scikit-learn предоставляет готовые реализации регрессионных моделей, средства предобработки данных, разбиения на обучающую и тестовую выборки, кросс-валидации и оценки качества.

Цель работы: изучить инструменты регрессии Scikit-learn, построить и сравнить модель по варианту на реальном датасете, провести предобработку данных, оценить качество разными способами разбиения выборки, а также выполнить кластеризацию на том же наборе данных.

Задачи:

1. Изучить инструменты регрессии Scikit-learn.
2. Исследовать регрессор по варианту — KNeighborsRegressor.
3. Подобрать датасет, определить целевой столбец и признаки.
4. Подготовить данные, обучить модель на сырых и очищенных данных.
5. Сравнить holdout и кросс-валидацию.
6. Представить результаты в табличной и графической форме.
7. Выполнить кластеризацию и проанализировать результаты.

Инструменты: Python, pandas, matplotlib, Scikit-learn.

Основная часть

1. Инструменты регрессии Scikit-learn

В работе использованы:

Инструмент	Назначение
KNeighborsRegressor	Регрессия методом k ближайших соседей
Pipeline	Объединение предобработки и модели в один конвейер

ColumnTransformer	Разная обработка числовых и категориальных признаков
OneHotEncoder	Кодирование категориального признака wallsMaterial
StandardScaler	Масштабирование числовых признаков
train_test_split	Разбиение на обучающую и тестовую выборки (holdout)
KFold, cross_val_score	k-fold кросс-валидация
mean_absolute_error, r2_score + MAPE	Метрики качества регрессии
KMeans	Кластеризация и оценка её качества

2. Датасет

Источник: открытый набор данных объявлений о продаже квартир в Москве (ml_moscow_flats.csv).

Объём: 63 943 объекта после удаления строк с пропусками (из ~64 000).

Структура данных:

Столбец	Тип	Описание
wallsMaterial	категория	Материал стен (brick, panel, monolith и др.)
floorNumber	число	Этаж квартиры
floorsTotal	число	Этажность дома
totalArea	число	Общая площадь, кв. м
kitchenArea	число	Площадь кухни, кв. м
latitude	число	Широта
longitude	число	Долгота
price	число	Целевая переменная — цена, руб.

3. Выбор целевого столбца и признаков

Целевой столбец — price (цена квартиры).

Задача — предсказать рыночную стоимость по характеристикам объекта. Это типичная задача регрессии с непрерывным ответом.

Признаки (X): все столбцы, кроме price.

Обоснование:

- totalArea, kitchenArea — напрямую связаны с ценой (чем больше площадь, тем выше цена).
- floorNumber, floorsTotal — этаж и высота дома влияют на стоимость.
- wallsMaterial — отражает класс жилья (панель, кирпич, монолит и т.д.).
- latitude, longitude — географическое положение определяет район и транспортную доступность, что сильно влияет на цену в Москве.

Преобразование типов: числовые столбцы приведены к типу float, строки с пропусками в ключевых полях удалены. Категория wallsMaterial кодируется через OneHotEncoder при обучении модели.

4. Модель по варианту — KNeighborsRegressor

KNeighborsRegressor (kNN-регрессия) предсказывает значение как среднее (или взвешенное среднее) целевой переменной у k ближайших объектов обучающей выборки в пространстве признаков.

Параметры: n_neighbors=5.

Особенности:

- Не строит явную формулу, а опирается на локальную структуру данных.
- Чувствителен к масштабу признаков (координаты, площади, этажи имеют разный диапазон).
- Требуется кодирования категориальных признаков.

5. Предобработка данных

Этап	Сырые данные	Очищенные данные
------	--------------	------------------

Категории	OneHotEncoder	OneHotEncoder
Числовые признаки	без масштабирования	StandardScaler
Конвейер	Pipeline (prep + kNN)	Pipeline (prep + kNN)

Масштабирование важно для kNN, так как расстояние между объектами должно учитывать все признаки равномерно.

6. Методы формирования обучающей и тестовой выборки

1. Holdout (80/20) — данные один раз делятся на 80% обучение и 20% тест; модель обучается на train и оценивается на test.
2. 5-fold кросс-валидация — данные делятся на 5 частей; модель 5 раз обучается и проверяется на разных фолдах; итог — среднее значение метрики по всем фолдам.

Практическая часть

Ход выполнения

1. Загрузка файла ml_moscow_flats.csv, проверка пропусков и типов данных.
2. Разделение на признаки X и целевую переменную y (price).
3. П.6 — обучение KNeighborsRegressor на сырых данных (кодирование категорий без масштабирования числовых признаков), оценка на holdout 80/20.
4. П.7–8 — обучение на очищенных данных (ONE + StandardScaler):
5. holdout 80/20;
6. 5-fold кросс-валидация.
7. Сводная таблица метрик R^2 , MAE, MAPE и время обучения.
8. Построение графиков: сравнение R^2 по этапам; диаграмма «факт vs прогноз».
9. Кластеризация — KMeans с $k=5$ на масштабированных признаках (без price при обучении), столбчатая диаграмма средней цены по кластерам (млн руб.)

Результаты


Регрессия

Этап	R^2	MAE, руб.	MAPE, %	Время, с
Сырые данные (holdout 80/20)	0,660	5 327 408	24,4	0,44
Очищенные данные (holdout 80/20)	0,700	3 890 376	14,4	0,9
Очищенные данные (5-fold CV)	0,713	3 847 108	14,6	4,48


MAE выражен в рублях и выглядит большим из-за высоких цен в Москве; MAPE (~14% на очищенных данных) показывает относительную ошибку удобнее для интерпретации

Графики:

1. Зависимость R^2 от этапа обработки (сырые / holdout / CV).



2. Диаграмма рассеяния «фактическая цена — прогноз» для очищенных данных.



Кластеризация (KMeans, k = 5)

Коэффициент силуэта: 0.1665

	count	mean_mln	median_mln
Cluster			
0	15709	10.01	8.85
1	14782	11.67	9.70
2	7382	24.45	19.80
3	22730	15.58	12.10
4	3340	88.63	57.32

На масштабированных признаках (без столбца price) выполнена кластеризация KMeans с числом кластеров $k = 5$.

График: столбчатая диаграмма средней цены в каждом кластере (млн руб.).



По высоте столбцов видно, что кластеры соответствуют разным ценовым сегментам: есть группы с относительно низкой и высокой средней ценой.

Логика формирования кластеров: KMeans объединяет квартиры с близкими площадью, этажом, координатами и типом дома. Цена при разбиении не используется; различие средних цен по кластерам показывает, что выделенные группы связаны с уровнем стоимости на рынке.

Выводы

1. Инструменты Scikit-learn позволяют в едином конвейере (Pipeline) совместить предобработку и регрессию, что исключает утечку информации из тестовой выборки в обучение.
2. Датасет квартир Москвы подходит для задачи регрессии: целевая переменная price непрерывна, признаки отражают характеристики жилья и местоположение.
3. KNeighborsRegressor показал приемлемое качество: $R^2 \approx 0,66$ на сырых данных и $\approx 0,70$ – $0,71$ после предобработки. Модель объясняет около 70% дисперсии цены.

4. Предобработка улучшает результат: масштабирование числовых признаков снизило MAE с ~5,3 млн до ~3,9 млн руб. и повысило R^2 . MAPE снизился с ~24% на сырых данных до ~14% на очищенных, что подтверждает улучшение прогноза в относительных единицах. Это ожидаемо для kNN, так как алгоритм основан на метрике расстояния.
5. Holdout и кросс-валидация дают близкие оценки ($R^2 \approx 0,70$ и $0,71$), что говорит об устойчивости модели; Holdout и 5-fold CV на очищенных данных дают близкий R^2 (~0,70 и ~0,71), MAE и MAPE согласованы — модель ведёт себя стабильно.
6. Кластеризация KMeans ($k=5$) выделила пять сегментов с разной средней ценой; по столбчатой диаграмме видно неоднородность рынка (от более доступного до премиального жилья).
7. Практическая значимость: построенная модель может использоваться для грубой оценки рыночной цены квартиры по её параметрам; для более точных прогнозов потребуются дополнительные признаки (метро, год постройки и др.) и, возможно, другие модели.